

G A N s t r u d y
박 이 삭

Info_GAN

Interpretable Representation Learning by
Information Maximizing Generative Adversarial Nets

Contents

Unit 01 | disentangled representation

Unit 02 | background

Unit 03 | information theory

Unit 04 | info_GAN

Unit 05 | result

Generate Model?

- $P(x)$ 의 분포를 모르지만 샘플은 얻을 수 있는 경우, 유사한 $Q(x)$ 를 만든다.
- 유사함의 기준: KL 다이베 전스
- + 만들기에 그치는 것이 아니라 얼굴데이터를 생성할 경우
눈의 색, hairstyle, 안경의 유무 등의 representation을 학습 할 수 있다면?

Motivation

기존 GAN에서 학습을 진행할 때

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

z에 제약이 없기 때문에 이미지의 특징을 잡아 낼 필요가 없었다. (혹은 잡아내지 못했다.)

How can we achieve


unsupervised learning of **disentangled** representation?

In general, learned representation is entangled,
i.e. encoded in a data space in a complicated manner

그렇기 때문에 이미지의 특성이 꼬인(entangled) 형태로 학습이 된다.

When a representation is **disentangled**, it would be
more interpretable and easier to apply to tasks

꼬임을 풀어(disentangled) 학습을 진행 한다면 특징들을 잡아 낼 수 있을 것이다.



지도 학습보다는 비지도 학습으로

Label을 이용해 특징을 학습하기 보다 연속형(혹은 범주형)변수를
이용해 특징을 학습시키는 것

Latent code 'C' 는 데이터의 특징을 목표로 하는 변수

예) $c_1 \sim \text{category}(k = 10, p = 0.1)$ 이면 mnist의 0~9까지 대응시켜 CGAN의 역할도 가능
 $c_2 \sim \text{unif}(-1, 1)$ 이면 회전 **이나** 두께에 대응시킬 수 있다.

의미없는 code를 학습하는 것을 막기위해 info_GAN은 생성분포 G 와 c 에 상호 정보량(Mutual Information)이 높도록 제약조건을 부여한다.

$$I[c ; G(z, c)] \text{ 높아야 한다.}$$

Variational Information Maximization I

- 상호정보량 $I(\mathbf{c}; G(\mathbf{z}, \mathbf{c}))$ 을
 - 계산에 $P(\mathbf{c}|\mathbf{x})$ 가 필요하지만 직접 최대화가 불가능
 - 보조분포 $Q(\mathbf{c}|\mathbf{x})$ 를 사용하여 low limit을 구한다.
- Variational Information Maximization을 이용 [Barber and Agakov, 2003]
 - 보조분포를 도입시 KL 정보량으로 low limit을 설정


$$\begin{aligned} I(\mathbf{c}; G(\mathbf{z}, \mathbf{c})) &= H(\mathbf{c}) - H(\mathbf{c}|G(\mathbf{z}, \mathbf{c})) \\ &= \mathbb{E}_{\mathbf{x} \sim G(\mathbf{z}, \mathbf{c})} [\mathbb{E}_{\mathbf{c}' \sim P(\mathbf{c}|\mathbf{x})} [\log P(\mathbf{c}'|\mathbf{x})]] + H(\mathbf{c}) \\ &= \mathbb{E}_{\mathbf{x} \sim G(\mathbf{z}, \mathbf{c})} [\underbrace{D_{\text{KL}}(P(\cdot|\mathbf{x}) \parallel Q(\cdot|\mathbf{x}))}_{\geq 0} + \mathbb{E}_{\mathbf{c}' \sim P(\mathbf{c}|\mathbf{x})} [\log Q(\mathbf{c}'|\mathbf{x})]] + H(\mathbf{c}) \\ &\geq \mathbb{E}_{\mathbf{x} \sim G(\mathbf{z}, \mathbf{c})} [\mathbb{E}_{\mathbf{c}' \sim P(\mathbf{c}|\mathbf{x})} [\log Q(\mathbf{c}'|\mathbf{x})]] + H(\mathbf{c}) \end{aligned}$$

Unit 02 | Background-information theory

$I[c; G(z, c)]$? 엔트로피

정보의 양을 $h(x) = -\log p(x)$ 로 정의하면

(낮은 확률로 발생하는 사건을 높은 정보량을 부여하기 위해)



$h(x)$ 의 기댓값 $-\sum_x p(x) \log p(x) = H(x)$ 라고 정의하고 '엔트로피' 라고 부른다.

$H(x, y)$ 는 흔히 말하는 cross-entropy 라고 하며 $H(x, y) = -\sum_x p(x) \log q(y)$ 로 정의한다.

$I[c ; G(z, c)]?$

KL 다이버전스는 두 확률분포 p q 간의 괴리로 정의하며

$KL(p||q) = H(x, y) - H(x)$ 로 정의하고 GAN에 빗대어 설명한다면

“어떤 확률분포 p 가 있을 때 P 를 알 수 없어, P 에서 얻은 sample을 이용해 근사적으로 q 를 만들어 p 대신 사용할 때 생기는 엔트로피 변화의 의미” 이다.

$$\begin{aligned} &= - \sum_x p(x) \log q(x) - \left(- \sum_x p(x) \log p(x) \right) \\ &= - \sum_x p(x) \log \frac{p(x)}{q(x)} \end{aligned}$$

Unit 02 | Background-information theory

$I[c ; G(z, c)]?$

결합 확률분포(joint)도 GAN에서 빼놓을 수 없다...

$p(x, y) = \int_x p(x)p(y|x) dx$ 로 정의 된다. x 를 이미 알고 있다면 결합분포를 구하는데 필요한 정보량은 $-\log p(y|x)$ 가 된다.

이를 조건부 엔트로피라고 하고

$H(y|x) = -\sum_x \sum_y p(x, y) \log p(y|x)$ 로 정의한다.

$= \sum_x p(x) \sum_y p(y|x) \log (y|x)$ 베이즈 규칙

조건부 엔트로피는 다음과 같은 성질이 있다.

(x, y) 를 설명하기 위해서는 x 만의 정보 $H(x)$ 와 $H(x, y) = H(y|x) + H(x)$
 x 가 주어졌을 때 y 를 기술하는데 필요한 정보의 합

$I[c; G(z, c)]?$

마지막으로 결합분포(joint)와 주변분포(marginal)를 정보 기준으로 살펴보자.

만약, x 와 y 가 독립이라면 $p(x, y) = p(x)p(y)$ 가 될 것이다.

하지만 독립이 아니라면 둘의 차이는 존재하고 이를 KL로 측정할 수 있다.

$$\begin{aligned} KL(p(x, y) || p(x)p(y)) &= \sum_x \sum_y p(x, y) \log p(x)p(y) - \{- \sum_x \sum_y p(x, y) \log p(x, y)\} \\ &= \sum_x \sum_y p(x, y) \log \frac{p(x, y)}{p(x)p(y)} = H(x) - H(x|y) \end{aligned}$$

이를 상호 정보라고 한다.

Unit 04 Info_GAN

$I[x; y] \geq 0$ 이고 독립일때 0을 만족한다. 즉, $I[x; y]$ 는 연관이 있다면 0보다 큰 값을 갖는다.

$$\min_G \max_D V_I = V(G, D) - \lambda I(c; G(z, c))$$

Info_GAN 에서 상보 정보량은 c 가 변하면 생성함수 G 도 변화시켜 만들어 내는 이미지를 변화하게끔 학습시키는 것!!

$$I[c; G(z, c)] = H(c) - H(c|G(z, c))$$

$$= \sum_c \sum_x p(c, x) \log p(c|x), \text{ 단 } x \sim G(z, c)$$

$$= \sum_x p(x) \sum_c p(c|x) \log p(c|x) \quad p(c|x) \text{가 필요하지만 } p(x) \text{는 구할 수 없다.}$$

$$= \sum_x p(x) \sum_c p(c|x) \log \frac{P(c|x)}{Q(c|x)} Q(c|x) \quad Q(c|x) \text{라는 보조분포(auxiliary)를 이용해 근사시키는 방법을 이용한다.}$$

$$= \sum_x p(x) \{ \underbrace{\sum_c p(c|x) \log \frac{p(c|x)}{Q(c|x)}}_{\text{KL다이버전스} \geq 0} + \sum_c p(c|x) \log Q(c|x) \}$$

$$\therefore I(c; G(z, c)) \geq \sum_x p(x) \sum_c p(c|x) \log Q(c|x) + H(c)$$

$$\begin{aligned}
\mathbb{E}_{x \sim X, y \sim Y|x} [f(x, y)] &= \int_{\mathcal{X}} \int_{\mathcal{Y}} P(x)P(y|x)f(x, y)dydx \quad (\because \text{Definition of pdf}) \\
&= \int_{\mathcal{X}} \int_{\mathcal{Y}} P(x, y)f(x, y)dydx \quad (\because \text{Bayes rule}) \\
&= \int_{\mathcal{X}} \int_{\mathcal{Y}} P(x', y)f(x', y)dydx' \quad (\because \text{no difference}) \\
&= \int_{\mathcal{X}} \int_{\mathcal{Y}} \left[\int_{\mathcal{X}} P(x|y)dx \right] P(x', y)f(x', y)dydx' \quad \left(\because \int_{\mathcal{X}} P(x|y)dx = 1 \right) \\
&= \int_{\mathcal{X}} \int_{\mathcal{Y}} \left[\int_{\mathcal{X}} P(x|y) \frac{P(y)}{P(y)} dx \right] P(x', y)f(x', y)dydx' \quad (\because \text{Bayes rule}) \\
&= \int_{\mathcal{X}} \int_{\mathcal{Y}} \left[\int_{\mathcal{X}} P(x, y)dx \right] P(x'|y)f(x', y)dydx' \quad (\because \text{Bayes rule}) \\
&= \int_{\mathcal{X}} \int_{\mathcal{Y}} \left[\int_{\mathcal{X}} P(x)P(y|x)dx \right] P(x'|y)f(x', y)dydx' \quad (\because \text{Bayes rule}) \\
&= \int_{\mathcal{X}} \int_{\mathcal{Y}} \int_{\mathcal{X}} P(x)P(y|x)P(x'|y)f(x', y)dx'dydx \quad (\because \text{Fubini theorem}) \\
&= \mathbb{E}_{x \sim X, y \sim Y|x, x' \sim X|y} [f(x', y)]
\end{aligned}$$

Unit 04 InfoGAN

$$\begin{aligned} L_I(G, Q) &= E_{c \sim P(c). x \sim G(z, c)} [\log Q(c|x)] + H(c) && \leftarrow \text{Goal eq} \\ &= E_{c \sim P(c), x \sim P_G(x|z, c)} [\log Q(c|x)] + H(c) \\ &= E_{c \sim P(c), x \sim P_G(x|z, c), c' \sim P(c|x)} [\log Q(c'|x)] + H(c) && \leftarrow \text{Lemma 5.1} \\ &= E_{x \sim P_G(x|z, c), c' \sim P(c|x)} [\log Q(c'|x)] + H(c) \\ &= E_{x \sim P_G(x|z, c)} \left[E_{c' \sim P(c|x)} [\log Q(c'|x)] \right] + H(c) \\ &\leq I(c; G(z, c)) \end{aligned}$$

최종적으로 다음과 같은 식을 얻을 수 있다.

$$\min_{G,Q} \max_D V_{InfoGAN}(D, G, Q) = V(D, G) - \lambda L_I(G, Q)$$
$$L_I(G, Q) = E_{c \sim P(c). x \sim G(z, c)} [\log Q(c|x)] + H(c)$$

생성된 c 는 G 에 영향을 준다.

G 에서 x 를 생성한 다음 Q 를 통해 다시 c 로 돌아 온다.

그런데!! 다시 돌아온 c 가 처음과 같아야 한다는 내용!


이를 Reconstruction loss 라고 한다.

최종적으로 다음과 같은 식을 얻을 수 있다.


$$\min_{G,Q} \max_D V_{InfoGAN}(D, G, Q) = V(D, G) - \lambda L_I(G, Q)$$
$$L_I(G, Q) = E_{c \sim P(c). x \sim G(z, c)} [\log Q(c|x)] + H(c)$$

Intuitions


- * $V(D, G)$ 는 기존 GAN과 같다.
- * G 와 Q 는 L_I 도 최대화 해야한다.
- * 즉 Q 는 $G(z, c)$ 를 다시 c 로 잘 바꿔야 하고,
- * G 는 Q 가 잘 바꿀 수 있도록 $x = G(z, c)$ 를 생성해야 한다.




(a) Varying c_1 on InfoGAN (Digit type)



(b) Varying c_1 on regular GAN (No clear meaning)



(c) Varying c_2 from -2 to 2 on InfoGAN (Rotation)



(d) Varying c_3 from -2 to 2 on InfoGAN (Width)

Unit 05 | result



(a) Azimuth (pose)

(b) Elevation



(c) Lighting

(d) Wide or Narrow



(a) Rotation

(b) Width

PR-022:infoGAN https://www.youtube.com/watch?v=4jbgniqt_Q&t=905s

초짜 대학원생 <http://jaejunyoo.blogspot.com/2017/03/infogan-1.html>

infoGAN 코드 : <https://github.com/openai/infoGAN>

Lemma5.1 해석:

<https://www.facebook.com/groups/TensorFlowKR/permalink/484676605206736/>

상호 정보량: <http://sanghyukchun.github.io/62/>
<http://norman3.github.io/prml/docs/chapter01/6.html>